

# Classification of Musical Periods

Gerardo Mauricio Toledo Acosta

Postdoctorado

Laboratorio de Semántica Computacional

Centro de Investigación en Ciencias

UAEM

July 4, 2020

# Objetivo

En la historia de la música hay varios periodos muy diferentes:



# Objetivo

En la historia de la música hay varios periodos muy diferentes:

- Periodo barroco: 1600-1750.
- Periodo clásico: 1750-1820.
- Periodo romántico: 1820-1900.

# Objetivo

En la historia de la música hay varios periodos muy diferentes:

- Periodo barroco: 1600-1750.
- Periodo clásico: 1750-1820.
- Periodo romántico: 1820-1900.

Objetivo [v0]

*¿Es posible clasificar la música en estos periodos usando una red neuronal?*

# Objetivo

En la historia de la música hay varios periodos muy diferentes:

- Periodo barroco: 1600-1750.
- Periodo clásico: 1750-1820.
- Periodo romántico: 1820-1900.

Objetivo [v0]

*¿Es posible clasificar la música en estos periodos usando una red neuronal?*

Objetivo [v1]

*¿Es posible clasificar representaciones gráficas de la música en estos periodos usando una red neuronal?*

## 2. ¿Cómo abordar el problema?

Tengo un dataset de 1549 archivos midi de piezas de piano de los tres periodos.



## 2. ¿Cómo abordar el problema?

Tengo un dataset de 1549 archivos midi de piezas de piano de los tres periodos.

Origen: Kaggle, The MAESTRO Dataset (Tensorflow), websites de midis.




## 2. ¿Cómo abordar el problema?

Tengo un dataset de 1549 archivos midi de piezas de piano de los tres periodos.


Origen: Kaggle, The MAESTRO Dataset (Tensorflow), websites de midis.

He generado un piano-roll de cada archivo midi:


Barroco



Clásico



Romántico






## 2. ¿Cómo abordar el problema?

Tengo un dataset de 1549 archivos midi de piezas de piano de los tres periodos.


Origen: Kaggle, The MAESTRO Dataset (Tensorflow), websites de midis.

He generado un piano-roll de cada archivo midi:


Barroco



Clásico



Romántico



Objetivo [v2]

*Entrenar una red neuronal para clasificar las imagenes.*


# Posibles dificultades derivadas del dataset

- No son tantas instancias, 1893.



# Posibles dificultades derivadas del dataset

- No son tantas instancias, 1893.
- Tamaños relativos desproporcionados






# Posibles dificultades derivadas del dataset

- No son tantas instancias, 1893.
- Tamaños relativos desproporcionados



- Configuración correcta de los parámetros de las imágenes.

# Primeros resultados



Hay muy pocas instancias de entrenamiento.

# PCA sobre las features



- Cada archivo MIDI tiene asociado un tensor  $\text{Canales} \times \text{Rango} \times \text{Duración}$ , se suma sobre el primer eje para tener una matriz  $\text{Rango} \times \text{Duración}$ , la aplanamos:



- Formamos una matriz donde cada renglón es un archivo MIDI aplanado. Tiene forma  $1893 \times 29965936$ . Aproximadamente, sólo el 2% son datos.
- Debido al tamaño de la matriz, se usan matrices sparse de scipy. En lugar de PCA, usamos truncatedSVD.

# PCA sobre las features


- Sólo pude calcular 6 componentes.




- Alternativas: Latent Dirichlet Allocation (LDA), MiniBatchSparsePCA.
- Falta aplicar regresión logística o algún otro método de clasificación.

# PCA sobre las features

- Podría reducirse el tamaño de las matrices en el segundo eje:





- El segundo eje del tensor se redujo lo más posible:





# Aumento de instancias

- Transposiciones: Tocar la misma pieza un poco más agudo o grave. Con esto, conseguí 4 veces más instancias.



- Puede haber otras opciones para alterar las imágenes de una *buena* manera (simetrías, re-arreglos).

# Nuevos resultados